

## **Titlul proiectului de cercetare:** Batch vs Streaming în sisteme de date

### **Stadiul actual:**

În ultimii ani, sistemele informatice au ajuns să proceseze cantități tot mai mari de date, atât date istorice, cât și date generate continuu. Din acest motiv, două metode importante de procesare sunt folosite frecvent: procesarea batch și procesarea streaming.

Procesarea batch este potrivită atunci când datele pot fi colectate și analizate periodic. Aceasta este folosită de obicei pentru rapoarte, statistici și agregări care nu trebuie să fie disponibile instant. De exemplu, un sistem poate calcula la anumite intervale media valorilor sau evoluția unor indicatori.

Pe de altă parte, procesarea streaming este folosită atunci când datele trebuie analizate imediat după ce sunt generate. Această abordare este importantă în aplicații unde timpul de reacție contează, cum ar fi monitorizarea în timp real sau detecția de alerte. Datele sunt tratate ca un flux continuu de evenimente, nu ca un set fix.

În practică, cele două abordări nu sunt complet separate, ci pot fi folosite împreună. Batch-ul oferă o imagine agregată asupra datelor, iar streaming-ul permite reacții rapide. Proiectul de față pornește de la această idee și propune o aplicație demonstrativă care evidențiază diferențele dintre ele.

Domeniul medical este folosit doar ca scenariu de demonstrație, deoarece oferă un exemplu clar de date generate continuu. Scopul proiectului nu este dezvoltarea unei aplicații medicale reale, ci utilizarea unui demo realist inspirat dintr-un site de spital, pentru ca soluția să fie cât mai user-friendly, obiectivul principal fiind evidențierea diferenței dintre batch și streaming.

### **Abordare:**

Problema abordată în acest proiect este înțelegerea și demonstrarea practică a diferenței dintre procesarea batch și procesarea streaming într-un sistem de date. În teorie, aceste concepte pot fi explicate destul de simplu, dar diferențele devin mult mai clare atunci când sunt puse într-o aplicație funcțională. Din acest motiv, proiectul propune o aplicație web demonstrativă, inspirată dintr-un sistem de monitorizare pentru un spital.

Aplicația simulează pacienți care generează constant date medicale, cum ar fi pulsul, temperatura și nivelul de oxigen. Aceste date sunt folosite pentru a demonstra partea de streaming. În momentul în care anumite valori depășesc limite considerate normale, sistemul poate genera alerte. De exemplu, un puls foarte ridicat sau o saturație scăzută a oxigenului pot declanșa o alertă de tip warning sau critical. Această parte arată avantajul procesării streaming: sistemul poate reacționa rapid, aproape în timp real, fără să aștepte o analiză periodică.

În paralel, aplicația include și o componentă batch. Aceasta nu reacționează imediat la fiecare eveniment, ci procesează datele la anumite intervale. Prin batch se pot calcula statistici generale, medii, evoluții ale pacienților, distribuții pe departamente sau alte informații agregate. Această parte este utilă pentru a observa tendințe și pentru a obține o imagine mai clară asupra datelor acumulate.

Contribuția principală a proiectului constă în construirea unui sistem demonstrativ care pune față în față cele două abordări. În loc să fie prezentate doar teoretic, batch și streaming sunt integrate într-o aplicație vizuală, unde utilizatorul poate observa diferențele dintre ele. Streaming-ul este folosit pentru date live și alerte, iar batch-ul este folosit pentru statistici și analize periodice.

Arhitectura aplicației este împărțită în mai multe componente. Backend-ul gestionează logica aplicației și comunicarea cu baza de date. Kafka este folosit pentru partea de streaming, deoarece permite transmiterea evenimentelor în timp real. PostgreSQL este folosit pentru stocarea datelor, iar frontend-ul oferă o interfață vizuală prin care se pot urmări pacienții, alertele și rezultatele batch.

Frontend-ul are rolul de a face diferențele mai ușor de înțeles. În loc ca rezultatele să fie afișate doar în consolă sau în tabele simple, aplicația include dashboard-uri, grafice și carduri de status. Astfel, se poate observa clar ce informații apar imediat prin streaming și ce informații sunt generate periodic prin batch.

Un aspect important este că aplicația nu încearcă să fie o soluție medicală completă sau validată clinic. Datele sunt simulate și folosite doar pentru a crea un context realist. Alegerea unui sistem de tip spital ajută la demonstrarea proiectului, deoarece într-un astfel de scenariu există date continue, alerte și nevoia de analize istorice. Totuși, aceeași idee s-ar putea aplica și în alte domenii, precum industrie, transport, comerț online sau sisteme financiare.

Prin această abordare, proiectul evidențiază faptul că batch și streaming nu se exclud reciproc. Din contră, ele pot fi folosite împreună într-un sistem modern. Streaming-ul este potrivit pentru reacții rapide, iar batch-ul este potrivit pentru analiză și raportare. Aplicația propusă demonstrează practic această complementaritate.

### **Evaluarea abordării propuse:**

Pentru evaluarea aplicației au fost utilizate mai multe metrici care descriu comportamentul sistemului atât în cazul procesării streaming, cât și batch.

Latența medie pentru streaming este de aproximativ 125 ms, în timp ce pentru batch ajunge la aproximativ 311520 ms (aprox. 5 minute). Această diferență evidențiază clar avantajul procesării streaming în scenariile unde este necesară o reacție rapidă. Sistemul de streaming poate răspunde aproape instant la apariția unui eveniment, în timp ce procesarea batch introduce o întârziere semnificativă, deoarece datele sunt analizate la intervale de timp prestabilite.

Numărul total de evenimente procesate este de 17132, dintre care 3431 reprezintă alerte, rezultând un alert rate de aproximativ 20%. Rata de procesare este de aproximativ 4.75 evenimente pe secundă, ceea ce indică un flux constant și stabil de date, suficient pentru a simula un scenariu realist de monitorizare.

Diferența de latență dintre cele două abordări depășește 311000 ms, iar indicatorul de tip responsiveness ratio (~2488) arată de câte ori este mai rapidă procesarea streaming comparativ cu cea batch. De asemenea, se observă o diferență clară în modul de actualizare a datelor: în streaming, alertele sunt generate și vizibile continuu, în timp ce în batch acestea sunt actualizate doar la fiecare execuție a procesului, fiind odata la 30s.

În concluzie, rezultatele obținute confirmă diferențele fundamentale dintre cele două tipuri de procesare: streaming-ul este rapid și potrivit pentru monitorizare în timp real și reacții imediate, în timp ce batch-ul, deși mai lent, oferă o perspectivă agregată și este mai potrivit pentru analize și raportare.